

Universidad  
Industrial de  
Santander



# ***MODELO DE REGRESION***

# ***PREDICCION DE PRECIO DE AUTOS***

# ***BASADO EN CARACTERISTICAS***

# ***TECNICAS***

Proyecto Final - Inteligencia Artificial I

**Angela Lozano Pulido**  
**Nicolas Cardenas Rodríguez**



# PROBLEMA

Estimar el precio de un automovil es complejo: intervienen docenas de características técnicas que interactúan de forma no lineal y por consiguiente hace que los métodos tradicionales sean imprecisos y subjetivos.

Este fue nuestro punto de motivación para poder pensar en un modelo que nos pueda ayudar de una manera eficiente y sin utilizar tanta característica que no es fundamental a poder predecir el precio de un auto de acuerdo a características más específicas y con un impacto más directo.

## ¿QUE QUEREMOS LOGRAR?

1.

Construir un modelo capaz de predecir el precio de un automovil a partir de sus características más técnicas y concretas.

2.

Analizar cuáles son realmente las variables más influyentes en este modelo creado.

3.

Tener la certeza de garantizar la predicción completa del precio de un automovil en base a lo investigado en nuestro dataset.

# DATASET

305

**AUTOMOVILES**

## VARIABLES CATEGORICAS

- Fueotype → Tipo de combustible
- Aspiration → Aspiracion (std, turbo)
- Doornumber → Numero de puertas
- Carbody → Tipo de carroceria
- Enginetype → Tipo de motor
- Cylindernumber → Cantidad de cilindros

## VARIABLES NUMERICAS

- Enginesize → Tamaño del motor (cc)
- Boreratio → Relacion del diametro
- Horsepower → Caballos de fuerza
- Peakrpm → Maximas revoluciones por minuto

10

**VARIABLES DE ENTRADA**

6

**VARIABLES CATEGORICAS**

4

**VARIABLES NUMERICAS**

# ANALISIS EXPLORATORIO

## TURBO = MAS CARO

Los autos con aspiracion turbo tienen una mediana de precio notablemente superior a la mediana.

---

## CARROCERIA IMPORTA

Convertibles y hardtops concentran los precios mas altos. Hatchbacks y sedanes los mas economicos.

---

## CILINDROS CLAVE

Motores de 6 y 8 cilindros corresponden a los vehiculos que pueden llegar a tener un precio mas alto.

---

## MOTOR = PRECIO

Enginesize tiene correlacion positiva muy fuerte con el precio. Es la variable numerica mas predictiva.

---

## HORSEPOWER FUERTE

a mayor potencia, mayor precio de forma consistente. Segunda variable numerica mas importante.


---

## RPM IRRELEVANTE


peakrpm realmente no explica ni aporta mucho en la prediccion. Se puede decir que tiene correlacion negativa casi nula con el precio.

---

# COLUMNAS CATEGORICAS VS EL PRECIO




# COLUMNAS NUMERICAS VS EL PRECIO



# MODELOS USADOS EN REGRESION

- **RANDOM FOREST**
- **SUPPORT VECTOR MACHINE (SVM) LINEAR**
- **DECISION TREE**
- **CROSS VALIDATION**
- **MLP**

# ANÁLISIS DE RESULTADOS



## SVM (LINEAR)

La relación entre las características técnicas y el precio no es lineal, por lo que un kernel lineal no la captura. La std altísima en K=50 (1.48) confirma que el modelo es completamente inestable: depende mucho de qué datos caigan en cada fold

## DECISION TREE

El árbol memoriza el entrenamiento pero generaliza mal. Eso es overfitting clásico. A medida que K aumenta, los folds son más pequeños, el modelo tiene menos datos para aprender y su rendimiento colapsa.

## RANDOM FOREST

Random Forest es el único que supera el umbral de 0.8 con K=10, y aunque baja con K más grandes (normal, porque los folds tienen menos datos de entrenamiento), nunca colapsa.

# CONCLUSION

- Random Forest es el modelo ganador, consistente con lo encontrado previamente con el train/test split ( $R^2 = 0.823$ ). El K-Fold lo confirma de forma más robusta porque evalúa el modelo en múltiples particiones distintas de los datos, no solo una. El SVM lineal queda descartado por su incapacidad de capturar relaciones no lineales, y el Decision Tree sirve como referencia intermedia pero sufre de overfitting severo.
- Preprocesamiento clave: El LabelEncoder permitió integrar variables categóricas al modelo de forma eficiente y reproducible
- Herramienta funcional: Se logró construir el predictor interactivo que cualquier persona puede usar sin ningún tipo de conocimientos técnicos

THANK YOU

THANK YOU